ÇANKIRI KARATEKİN ÜNİVERSİTESİ

DERİN ÖĞRENME YÖNTEMLERİ KULLANILARAK X-RAY KEMİK GÖRÜNTÜLERİ İÇİN NORMALLİK VE ANORMALLİK TESPİTİ

Berre Zehra TOP, Akdenur YEGİN, Danışman: Dr. Öğretim Üyesi Seda ŞAHİN
Çankırı Karatekin Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü, Çankırı, Türkiye
Danışman e-mail: sedasahin@karatekin.edu.tr

GİRİŞ

Bu çalışmada, MURA-v1.1 veri seti kullanılarak X-ray kemik görüntülerinde anormallik olup olmadığını tahmin edebilen ve anormallikleri tespit edebilen farklı derin öğrenme yöntemleri kullanılmıştır. EfficientNetV2 B0 ,VGG16, DenseNet169, DenseNet201 ve ResNet50 modelleri, Kaggle'dan alınan 68.327 üst kemik röntgenini içeren MURA-v1.1 veri setine uygulanmıştır. Bu modeller, kemik anormalliklerini sınıflandırmak üzere özelleştirilmiştir. Çalışma, sağlıkta ortopedi ve yapay zekayı birleştirdiği için gelecek çalışmalar için yol gösterici olabilir.

MATERYAL VE YÖNTEM

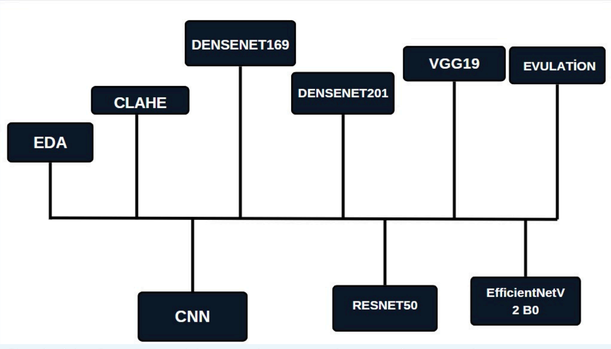
Mura-v1.1 Kas-iskelet radyografilerinde anomali tespiti için kullanılan geniş çaplı veri kümesi olan MURA, Stanford Üniversitesi Makine Öğrenmesi grubu tarafından hazırlanmıştır [1]. Veri tabanından bazı görüntüler şekil 1' de gösterilmiştir.



Şekil 1: Veri setinden görüntüler

KULLANILAN DERİN ÖĞRENME ALGORİTMALARI

DENSENET169
DENSENET201
RESNET50
VGG19
CNN
EFFİCİENTNETV2 B0
Bu algoritmalar şekil 2' de gösterilmiştir.

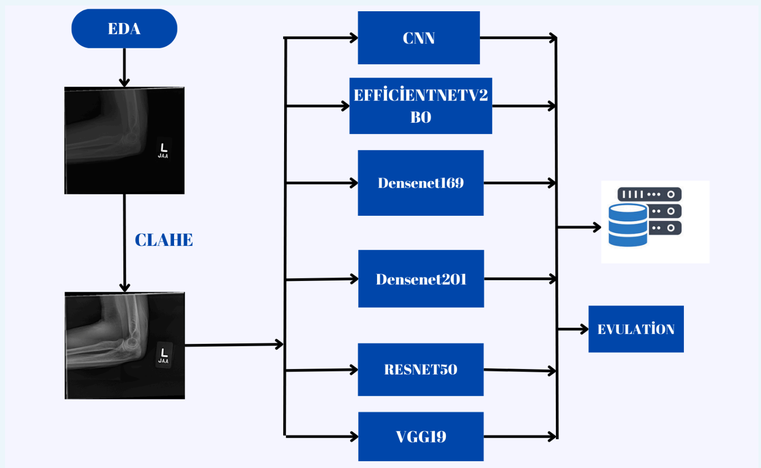


Şekil 2: Kullanılan algoritmalar

Üç farklı yaklaşım denedik:

1. Klasik bir Evrişimsel Sinir Ağını sıfırdan eğitmek.
2. Clahe ön işlemesi uygulamak.
3. Transfer-öğrenme: ImageNet üzerinde eğitilmiş ağırlıklarla bir DenseNet-169, DenseNet201, ResNet50, VGG19, CNN, EfficientNetV2 Bo üzerinde işlmemelr yaparak kullanıldı.

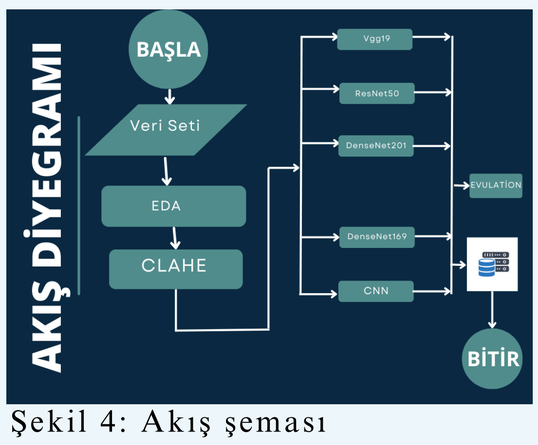
Bu yakşalımların adımları şekil 3'de gösterilmiştir



Şekil 3: Uygulanan adımlar

AKIŞ ŞEMASI

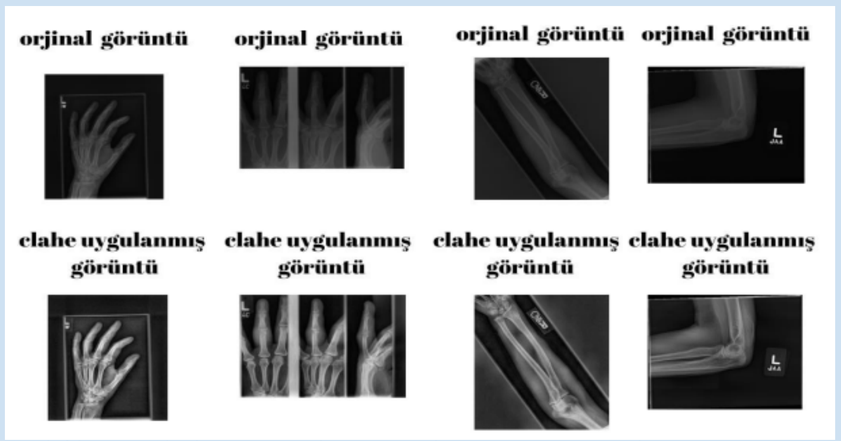
Başla: Akış şeması veri seti ile başlar. **Ön İşleme:** Veri seti üzerinde EDA (Keşifsel Veri Analizi) ve CLAHE (Kontrast Sınırlı Uyarlanabilir Histogram Eşitleme) yapılır. **Model Eğitimi:** Veriler, Vgg19, ResNet50, DenseNet201, DenseNet169 ve CNN gibi farklı derin öğrenme modelleriyle eğitilir. Değerlendirme ve **Sonuç:** Modellerin performansı değerlendirilir ve sonuçlar kaydedilir, ardından süreç biter.
Akış şeması şekil 4' de gösterilmiştir



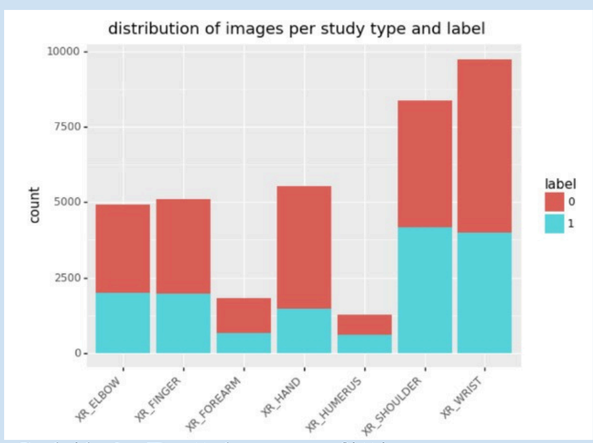
Şekil 4: Akış şeması

ÖN İŞLEME

Bu çalışmada yerel kontrast artışı için CLAHE [2] yöntemi kullanıldı. Bu yöntem, görüntünün çeşitli karo bölgeleri üzerinde histogramlara dayalı hesaplamalar yaparak yerel detayları, genel görüntüye göre daha koyu veya daha açık olan bölgelerde bile artırabilir. CLAHE yöntemi, histogramdaki artışın sınırlanması ve ardından artışın kırpılmasıyla gerçekleştirilir. Ancak, bu işlem homojen bölgelerde histogram benzeri gürültü oluşturabilir. Yeniden dağıtım adımı, bazı bölgelerin kırpma sınırını yeniden aşmasına neden olabilir..



Şekil 5: Clahe uygulanmış bazı görüntüler



Şekil 6: Dağılım grafiği

Özellikle MURA-v1.1 gibi büyük ve çeşitli bir veri setinde CLAHE'nin kullanılması, görüntülerin kalitesini artırarak hem manuel değerlendirmeler hem de otomatik teşhis algoritmaları için daha doğru ve güvenilir sonuçlar elde edilmesine yardımcı olur. Bu tür kontrast iyileştirme teknikleri, tıbbi görüntülemede tanı süreçlerinin etkinliğini artırmada kritik bir rol oynar. Bazı CLAHE uygulanmış görüntüler şekil 5‘ te gösterilmiştir.
Görüntünün çalışma türüne ve etikete göre dağılım grafiği bir veri setindeki görüntülerin belirli çalışma türlerine (eğitim, test) ve etiketlere (örneğin, sınıflar, kategoriler) göre nasıl dağıldığını gösterir. Bu, veri setinin yapısını ve dengeli olup olmadığını anlamak için kullanışlıdır. Dirsek, parmak, önkol, el, kazı kemiği, omuz, bilek görüntülerin dağılımı şekil 6' da gösterilmiştir.

SONUÇ

Bu tez çalışmasında, Derin Öğrenme, Yapay Zeka ve Makine Öğrenmesi yöntemleri kullanılarak kemiklerin anormal mi yoksa normal mi olduğunun tespiti yapılmıştır. Bu alandaki temel amaç, radyologlar ve doktorların kararlarını kolaylaştırarak daha doğru ve hızlı hastalık teşhisi yapmalarına yardımcı olmaktır.

Çalışmada, Stanford Üniversitesi'nin MURA (Musculoskeletal Radiographs) veri seti kullanılmıştır. Bu veri seti, çeşitli kemik görüntülerini içermekte olup, derin öğrenme modellerinin eğitilmesi için uygun bir kaynak sağlamaktadır.
Tez kapsamında, TensorFlow kütüphanesi kullanılarak VGG19, DenseNet169, DenseNet201, ResNet50 ve CNN mimarileri üzerinde derin öğrenme modelleri eğitilmiştir. Farklı medikal görüntüler için geliştirilen bu yöntemlerin sonuçları, önceki çalışmaların sonuçlarıyla karşılaştırılmıştır.

Bu sonuçlar, kullanılan derin öğrenme modellerinin kemik anormalliklerinin tespitinde ne derece başarılı olduğunu göstermektedir ve radyologlar ile doktorların tanı süreçlerinde bu tür yapay zeka tabanlı araçların kullanılmasının potansiyel faydalarını ortaya koymaktadır. Çalışmada elde edilen bulgular, medikal görüntü analizi alanında daha ileri araştırmalar için de önemli bir referans oluşturmaktadır. Bu sonuçlar tablo 1' de gösterilmiştir.

MODEL VE SONUÇLAR

EfficientNetV2 B0	MURA	Hand ve elbow görüntüleri birlikte alınmıştır	loss:	accuracy:	val_loss:	val_accuracy:
			0.0275	**0.9940**	0.0228	0.9946
DenseNet169	MURA			Dirsek	El	
			Cohen’s Kappa(k)	0.45	0.19	
			ROC AUC	0.78	0.65	
			F-1	0.61	0.30	
DenseNet201	MURA			Dirsek	El	
			Cohen’s Kappa(k)	0.56	0.34	
			ROC AUC	0.76	0.65	
			F-1	0.70	0.47	
ResNet50	MURA			Dirsek	El	
			Cohen’s Kappa(k)	0.65	0.59	
			ROC AUC	0.81	0.63	
			F-1	0.77	0.42	
DenseNet169-ResNet50	MURA			Dirsek	El	
			Cohen’s Kappa(k)	0.60	0.19	
			ROC AUC	0.78	0.58	
			F-1	0.73	0.30	
DenseNet201-ResNet50	MURA			Dirsek	El	
			Cohen’s Kappa(k)	0.59	0.31	
			ROC AUC	0.78	0.63	
			F-1	0.72	0.44	
VGG19	MURA			VALUE		
			LOSS	0.6139		
			Binary Accury	0.7163		
			Precision	0.6580		
			Recall	0.3524		
			F-1 Score	0.4590		
			ROC-AUC	0.6987		
CNN	MURA			EL	DİRSEK	
			LOSS	0.6732	0.5313	
			Binary Accury	0.7130	0.8095	
			Precision	0.4909	0.8175	
			Recall	0.5160	0.3592	
			ROC-AUC	0.7003	0.8181	

Tablo 1:Sonuçlar tablosu.

KAYNAKÇA

[1]. Abunasser, B. S., et al., “Breast Cancer Detection and Classification using Deep Learning Xception Algorithm” International Journal of Advanced Computer Science and Applications(IJACSA), vol. 13, no. 7, pp. 223-228, 2022
[2]. Karel Zuiderveld, “Graphics gems iv,” chapter Contrast Limited Adaptive Histogram Equalization, pp. 474–485. Academic Press Professional, Inc., San Diego, CA, USA, 1994